

“Sistem za preporuku algoritama i struktura podataka na osnovu tekstualnog opisa problema”

1. Definicija problema:

Cilj projekta je razviti sistem koji na osnovu tekstualnog opisa nekog problema automatski preporučuje odgovarajući algoritam ili strukturu podataka, na primjer :

Korisnikov unos:	Preporuka sistema:
„Želim da pronađem najkraći put između dva grada“	Dijkstra
„Moram da održavam najveći element nakon dodavanja i brisanja vrijednosti“	Heap

- Problem se svodi na klasifikaciju tekstualnih upita u unaprijed definisane klase (algoritmi ili strukture podataka).

2. Motivacija:

Odabir odgovarajućeg algoritma i/ili strukture podataka za neki problem je jedna od osnovnih, ali i najizazovnijih vještina u programiranju. Programeri se često suoče sa problemom da ne znaju da li je za određeni problem optimalno rješenje, na primjer, BFS ili Dijkstrin algoritam, ili da li treba koristiti Hash mapu ili binarno stablo pretrage. Sistem za preporuku algoritama i struktura podataka na osnovu tekstualnog opisa problema bi mogao biti koristan u sličnim situacijama, kao alat koji bi pomogao u izboru optimalnog rješenja.

Praktične primjene: u obrazovanju (unapređenje procesa učenja i vježbanja), u takmičarskom programiranju (pomažući takmičarima da brže prepoznaju obrasce i izaberu brži algoritam), u inženjerskoj praksi.

3. Skup podataka

Za potrebe ovog projekta bi se ručno kreirao skup podataka.

Skup bi sadržao oko 100-150 primjera problema opisanih prirodnim jezikom (50-75 za algoritme, 50-75 za strukture podataka). Skup podataka bi, takođe, sadržao varijacije problema (sinonime, parafraze, različite kontekste, dodatne attribute) i Null vrijednosti (radi preprocesiranja), kako bi bio bogatiji i realniji.

Primjer skupa podataka:

opis_problema	klasa
"Želim da pronađem najkraći put između dva čvora u grafu"	Dijkstra
"Moram da obiđem sve čvorove po nivoima"	BFS
"Želim da čuvam elemente sa brzim pretragama po ključu"	HashMap

4. Način pretprocesiranja podataka

Za Naive Bayes i KNN klasifikator:

- čišćenje teksta (lowercase, uklanjanje interpunkcije, stopwords),
- tokenizacija,
- pretvaranje teksta u numeričku reprezentaciju (TF-IDF vektorizacija),
- popunjavanje nedostajućih (Null) vrijednosti,
- analiza distribucije klasa (histogram)

Za transformer pristup:

- čišćenje teksta (lowercase, uklanjanje nepotrebnih simbola),
- pretrained tokenizer i Sentence-BERT model za generisanje semantičkih reprezentacija teksta (vektora - embedding)
- analiza distribucije klasa

5. Metodologija

Ulaz: tekstualni opis problema

Izlaz: preporučeni algoritam ili struktura podataka

Koraci:

1. Pretprocesiranje (objašnjeno u [4. tački](#)),
2. Treniranje i evaluacija klasifikacionih modela:
 - Naivni Bajes (baseline),
 - KNN klasifikator (sa različitim vrijednostima k),
 - Sentence-BERT + klasifikator (Logistička regresija/Random Forest)
3. Upoređivanje performansi svih modela, kako bismo znali koji je optimalan

Proces rada:

korisnik => unos teksta => NPL pretprocesiranje => model (NB / KNN / Sentence-BERT + klasifikator) => prikaz preporuke algoritma ili strukture podataka

6. Način evaluacije

Podaci se mogu podijeliti na 80% train i 20% test. Metrike: tačnost (accuracy), F1-score.

Evaluacija se vrši za oba modela (Naivni Bajes, KNN, Sentence-BERT + klasifikator) i porede se njihovi rezultati.

Vizualizacija:

- bar graf sa predikcijama po klasama,
- confusion matrix

7. Tehnologije

Python

Biblioteke: scikit-learn, numpy, pandas, matplotlib, transformers (HuggingFace), sentence-transformers

8. Relevantna literatura

- <https://faculty.uccs.edu/jkalita/wp-content/uploads/sites/45/2024/02/00Proceedings2016Optimized.pdf#page=21>
- <https://arxiv.org/pdf/2310.05791>
- https://pages.cs.wisc.edu/~gangluo/automatic_selection_review.pdf
- <https://sbert.net/>